

Construindo sua própria layer de observabilidade com AWS Lambda telemetry API

Gabriel Prando 10/2024

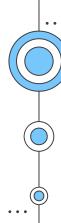


Quem é Gabriel Prando?



- Engenheiro de software/plataforma;
- Trabalhando com DevEx no iFood;
- Engenheiro de Computação (UTFPR-PB);
- Mestrando em Engenharia Elétrica e Computação (UTFPR-PB);
- Gosto de falar sobre Serverless, protocolos de comunicação e computação no geral;
- Em qualquer rede como @prandogabriel.





Agenda

- Alinhamento de conhecimento;
- Funcionamento lambda;
- Lambda Extensions;
- Lambda Layers;
- ❖ Telemetry API;
- Como criar uma layer de observabilidade.

• •



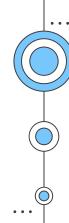
O que é serverlesscomputing? (computação sem servidor)



Serverless

'Sem servidor' descreve a experiência. Os servidores são invisíveis para o desenvolvedor, que não os vê, gerencia ou interage, mas eles existem sim.

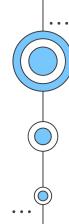




AWS Lambda

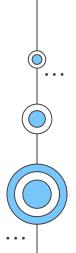
- Sem servidor para gerenciar;
- Escale com o uso;
- Orientado a eventos / triggers;
- Agnóstico a linguagem;
- Mais tempo para pensar no negócio (+dev -ops).



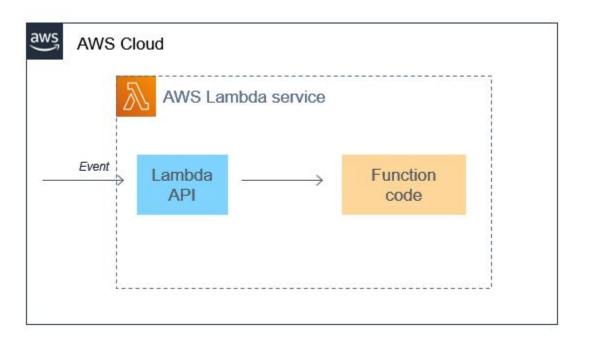


Casos de uso

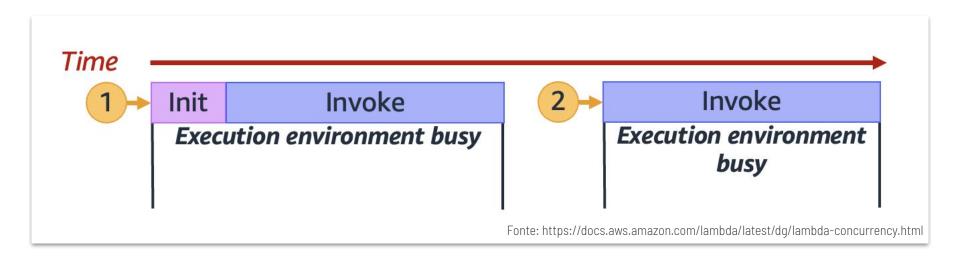
- Rest APIs;
- Processamento assíncrono;
- Processamento de dados (ETL);
- Startups (economia, foco dev, fácil desenvolvimento e manutenção).



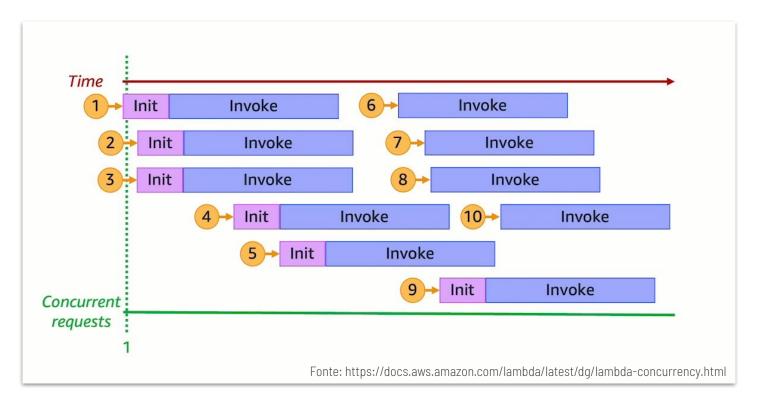
Como uma lambda é chamada?



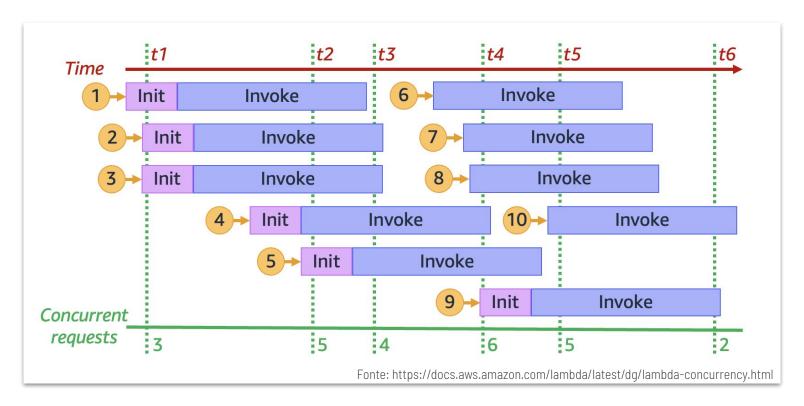
Como functions escalam?



Como functions escalam?



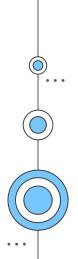
Como functions escalam?





Como lambdas escalam?

- Ponto de atenção:
 - Limite de 1000 instâncias simultâneas, por default:





Como lambdas escalam?

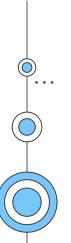
- Ponto de atenção:
 - ➤ Limite de 1000 instâncias simultâneas, por default:
 - 1000req * 200ms/req * 60s * 60min * 24h;
 - 5k req/s;
 - 300.000 req/min;
 - 18.000.000 req/hora;
 - 432.000.000 req/dia;
 - 12.960.000.000 req/mês.



Como lambdas escalam?

- Ponto de atenção:
 - ➤ Limite de 1000 instâncias simultâneas, por default:
 - 1000req * 200ms/req * 60s * 60min * 24h;
 - 5k req/s;
 - 300.000 req/min;
 - 18.000.000 req/hora;
 - 432.000.000 req/dia;
 - 12.960.000.000 req/mês.

Acho que da pra começar uma startup com isso...





E quanto custaria isso?

Unit conversions

Amount of memory allocated: 256 MB x 0.0009765625 GB in a MB = 0.25 GB

Amount of ephemeral storage allocated: 512 MB x 0.0009765625 GB in a MB = 0.5 GB

Pricing calculations

12,960,000,000 requests x 200 ms x 0.001 ms to sec conversion factor = 2,592,000,000.00 total compute (seconds)

0.25 GB x 2,592,000,000.00 seconds = 648,000,000.00 total compute (GB-s)

648,000,000.00 GB-s - 400000 free tier GB-s = 647,600,000.00 GB-s

Max (647600000.00 GB-s, 0) = 647,600,000.00 total billable GB-s

Tiered price for: 647,600,000.00 GB-s

647,600,000 GB-s x 0.0000166667 USD = 10,793.35 USD

Total tier cost = 10,793.3549 USD (monthly compute charges)

Monthly compute charges: 10,793.35 USD

12,960,000,000 requests - 1000000 free tier requests = 12,959,000,000 monthly billable requests

Max (12959000000 monthly billable requests, 0) = 12,959,000,000.00 total monthly billable requests

12,959,000,000.00 total monthly billable requests x 0.0000002 USD = 2,591.80 USD (monthly request charges)

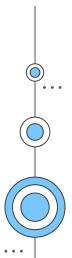
Monthly request charges: 2,591.80 USD

0.50 GB - 0.5 GB (no additional charge) = 0.00 GB billable ephemeral storage per function

Monthly ephemeral storage charges: 0 USD

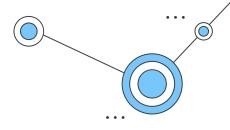
10,793.35 USD + 2,591.80 USD = 13,385.15 USD

Lambda costs - With Free Tier (monthly): 13,385.15 USD

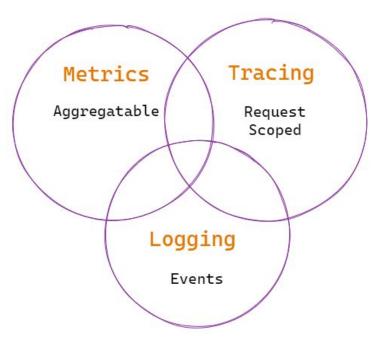


Como funciona observabilidade nesse econssitema?

Definindo observabilidade



- Pilares:
 - Logs (evidências);
 - Métricas (feedback | alarmes-dashboards);
 - > Trace (rastreamento);
- Compreender o estado de uma app;
- Identificar rapidamente (em tempo real):
 - > Falhas;
 - ➤ Gargalos;



Fonte: https://atatus.com/blog/observability-vs-monitoring/

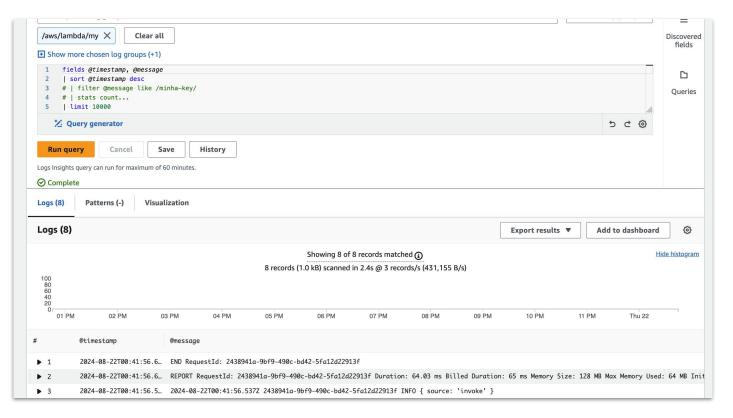




Anatomia de uma função lambda

```
console.log("Hello from function initalization");
exports.handler = async (event, context) => {
  console.log("Hello from function handler", {event});
}
```

Como vejo os logs da minha aplicação?



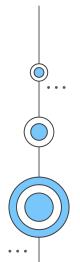
Como vejo os logs da minha aplicação?

#	@timestamp	@message
▶ 1	2024-09-15	END RequestId: b0ee24d5-1414-47c1-83bd-138daf1fb25f
▶ 2	2024-09-15	REPORT RequestId: b0ee24d5-1414-47c1-83bd-138daf1fb25f Duration: 1.22 ms Billed Duration: 2 ms Memory Size: 128 MB Max
▶ 3	2024-09-15	2024-09-15T17:11:58.730Z b0ee24d5-1414-47c1-83bd-138daf1fb25f INFO Hello from function Hanlder
4	2024-09-15	START RequestId: b0ee24d5-1414-47c1-83bd-138daf1fb25f Version: \$LATEST
▶ 5	2024-09-15	END RequestId: a8581695-5a8f-46b2-92bc-c483e45dece6
▶ 6	2024-09-15	REPORT RequestId: a8581695-5a8f-46b2-92bc-c483e45dece6 Duration: 2.76 ms Billed Duration: 3 ms Memory Size: 128 MB Max
▶ 7	2024-09-15	2024-09-15T17:11:07.748Z a8581695-5a8f-46b2-92bc-c483e45dece6 INFO Hello from function Hanlder
▶ 8	2024-09-15	START RequestId: a8581695-5a8f-46b2-92bc-c483e45dece6 Version: \$LATEST
▶ 9	2024-09-15	2024-09-15T17:11:07.741Z undefined INFO Hello from function initialization
▶ 10	2024-09-15	INIT_START Runtime Version: nodejs:20.v35 Runtime Version ARN: arn:aws:lambda:us-east-1::runtime:da38af670644eed7b5702



Opções para se ter observabilidade em um sistema complexo?

- Cloudwatch by default;
- Métricas via EMF;
- Alarms no CW através de métricas do CW;
- AWS X-Ray (tracing);
- Export do cloudwatch para outros serviços como opensearch;
- Envio dos dados para fontes terceiras:
 - Em tempo de execução;
 - ➤ Via layer/extensão;



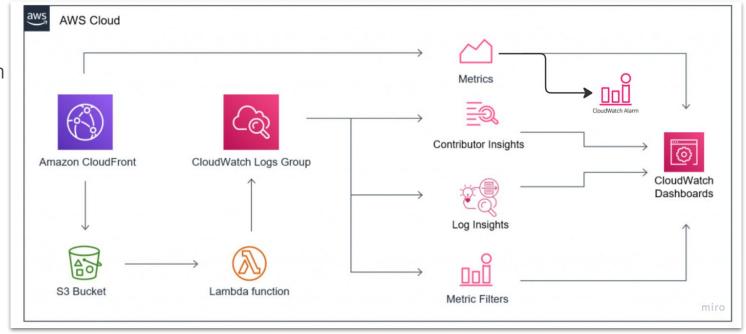
Métricas via EMF

- Log estruturado com pattern;
- Métricas custom automáticas publicadas no CW Metrics;
- Também é possível utilizar Metric
 Filter para algo similar.

```
"_aws": {
  "CloudWatchMetrics": [
      "Metrics": [{
          "Name": "Time",
          "Unit": "Milliseconds",
          "StorageResolution": 60
        }]
},
"Time": 1
```

Alarmes do Cloudwatch

 Publicado em tópicos ou ações de lambdas.



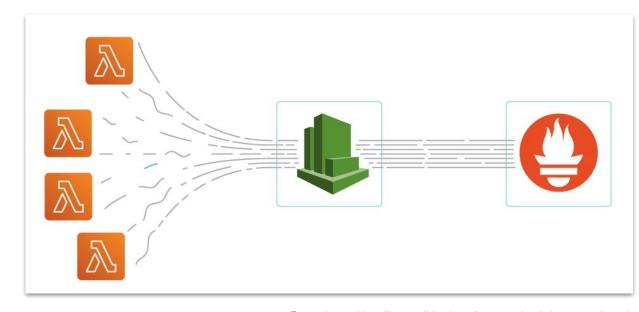
AWS X-ray

- Tracing/Tracking de requests;
- Instrumentação simples necessária.



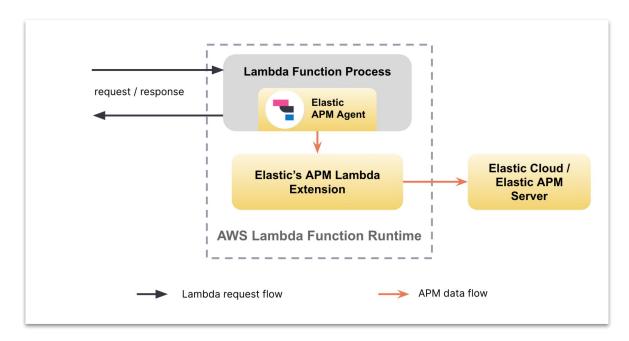
Export do cloudwatch

- "Plugável";
- Irá pagar por CW + Tráfego + Ferramenta (ELK, Prometheus...).



Envio dados para fontes terceiras

Envio em runtime ou background.

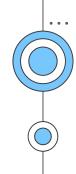


Fonte:



Dores do "by default AWS"

- Dificuldade de explorar logs:
 - Sintaxe própria do CW;
 - Limitação de 50 grupos de log por query;
 - Log descentralizado;
- Trace no X-Ray acaba sendo pouco eficiente;
- Limitação de não ter o serviço "em pé" direto limita alguns tipos de integrações;
- Dificuldade de sair a stack de serverless para outra arquitetura por tudo estar na AWS .

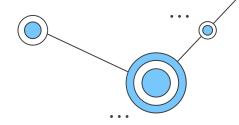


Como os grandes players de APM oferecem suporte a lambda?

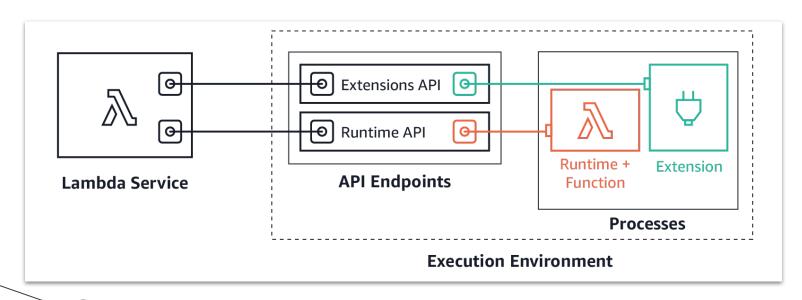
- Combinação de:
 - Lambda extensions;
 - ➤ Lambda Layer;
 - > Telemetry API.
- Alguns disponíveis: ELK, Datadog, New Relic, Open telemetry...

O que são esses componentes?

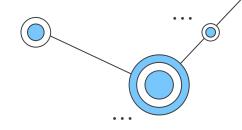
Lambda Extensions



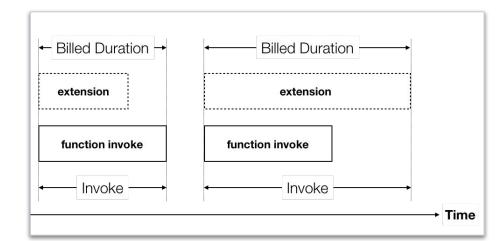
❖ Introduzida em 2020.

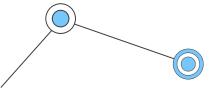


Lambda Extensions



- Facilitam a integração com outras ferramentas;
- Execução da função não depende da extension.

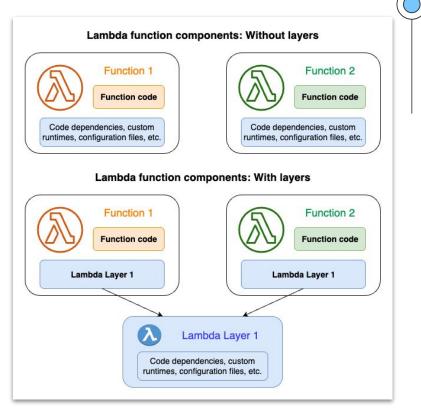






Lambda layers

- Arquivo .zip de conteúdo compartilhado;
- Empacote e compartilhe:
 - Dependências e bibliotecas;
 - Runtime personalizado;
 - Arquivos de configuração.





Lambda layers

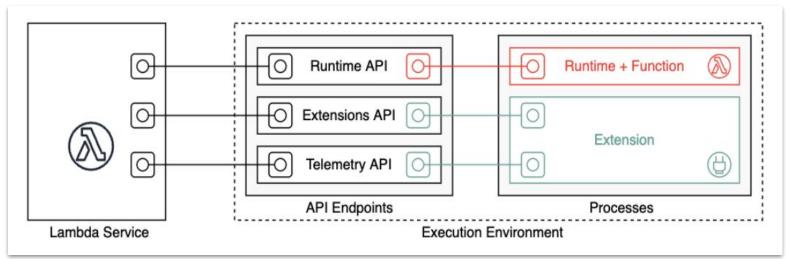
```
Description: CloudFormation Template for Lambda Function with Lambda Layer
 MyLambdaLayer:
    Type: AWS::Lambda::LayerVersion
      LayerName: my-lambda-layer
      Description: My Lambda Layer
        S3Bucket: amzn-s3-demo-bucket
        S3Key: my-layer.zip
        - python3.9
        - python3.10
        - python3.11
 MyLambdaFunction:
    Type: AWS::Lambda::Function
      FunctionName: my-lambda-function
      Runtime: python3.9
      Handler: index.handler
      Timeout: 10

    AWSLambdaBasicExecutionRole

        - AWSLambda ReadOnlyAccess
        AWSXrayWriteOnlyAccess
        !Ref MyLambdaLayer
```

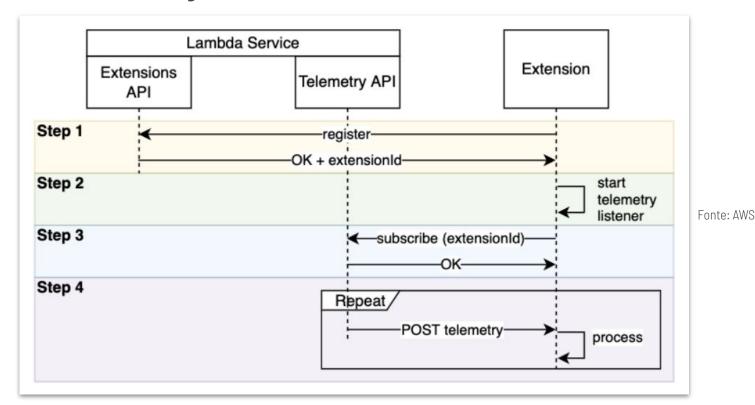
Telemetry API

- Possibilita extensões acessar dados de telemetria em tempo real;
- Logs, trace, métricas, métricas de plataforma;
- Possibilidade subscrever via extensão (infinitas possibilidades).

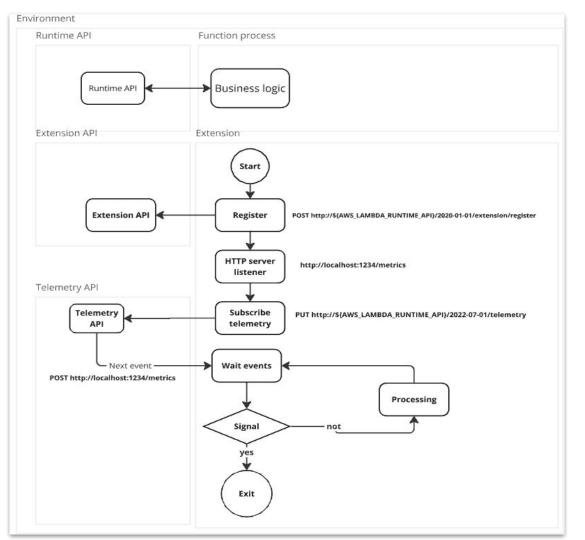




Como juntar tudo isso para criar sua layer de observabilidade?



Como juntar tudo isso



Processamento dos eventos

Batches de uma ou mais execuções;

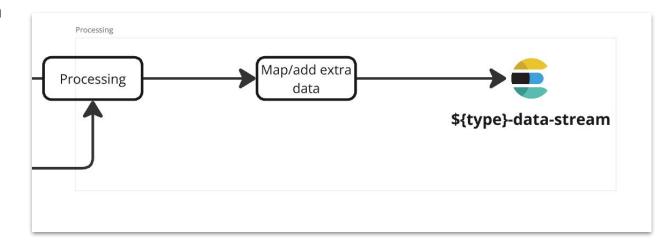
```
"time": "2022-10-12T00:03:50.000Z",
      "requestId": "989ffbf8-9ace-4817-a57c-e4dd734019ee"
```

```
. . .
    "time": "2022-10-12T00:01:15.000Z",
      "requestId": "6d68ca91-49c9-448d-89b8-7ca3e6dc66aa"
      "timestamp": "2022-10-12T00:03:50.000Z",
      "requestId": "79b4f56e-95b1-4643-9700-2807f4e68189"
      "message": "Hello world, I am a function!"
```

Fonte: AWS 38

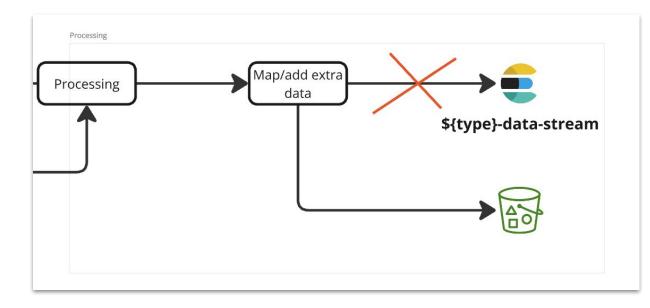
Processamento dos eventos

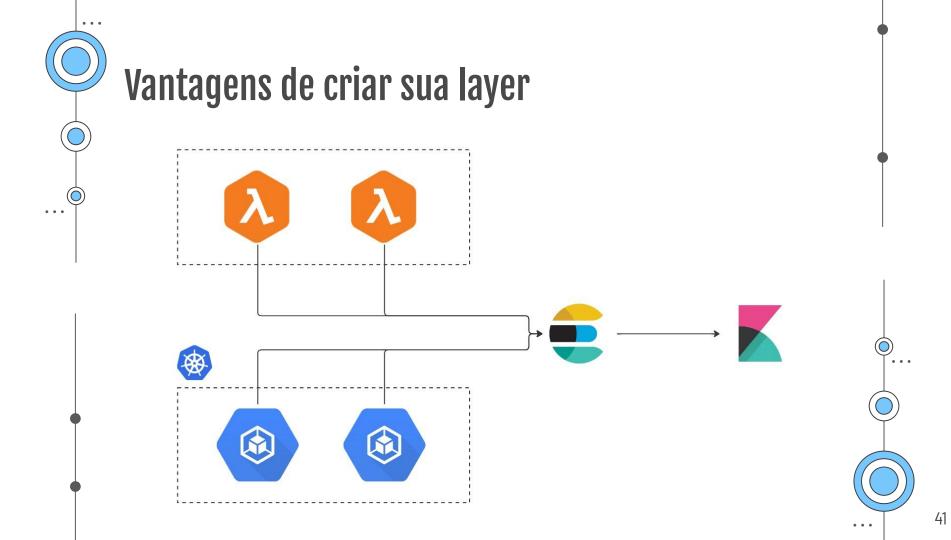
- Bulk/batch add;
- Enriquecer dados com base no tipo;



Processamento dos eventos

- Fallbacks;
- Várias possibilidades.

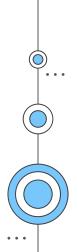






Vantagens de criar sua layer

- Log centralizado;
- Interoperabilidade entre sistemas;
- Gestão facilitada.





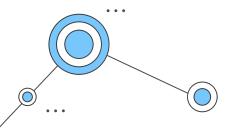
Referências

- https://aws.amazon.com/lambda/sla/historical/
- https://docs.aws.amazon.com/lambda/latest/dg/lambda-runtime-environment.html
- https://docs.aws.amazon.com/lambda/latest/dg/lambda-concurrency.html
- https://catalog.workshops.aws/lambdaextensions/en-US
- https://docs.aws.amazon.com/lambda/latest/dg/runtimes-extensions-api.html
- https://docs.aws.amazon.com/lambda/latest/dg/chapter-layers.html
- https://docs.aws.amazon.com/lambda/latest/dg/telemetry-api.html
- https://github.com/aws-samples/aws-lambda-extensions





Obrigado!



Aponte o celular e conecte-se:)



SCAN ME!